UNIVERSIDAD VERACRUZANA

Análisis y Predicción de la Contratación de Depósitos Bancarios mediante CRISP

Lic. Ingeniería en ciencia de datos.

Experiencia educativa: Metodología de la investigación

Docente: Mtra. Lorena Lopez Lozada.

Realizado por los alumnos:

José Antonio Hernández Carmona, María Fernanda Arellano Pérez & Daira Lisset Landa Apolinar

21 de septiembre del 2026

FACULTAD DE ESTADISTICA E INFORMATICA, XALAPA, VERACRUZ.

Introducción.....1

Objetivos.....2

METODOLOGIA.....3

COMPRENSION DE DATOS.....4

Preparación de los datos.....5

RESULTADOS.....6

CONCLUSION 7

REFERENCIAS.....8

1. Introducción

El análisis de datos y la minería de datos permiten obtener información útil a partir de grandes cantidades de datos y apoyar la toma de decisiones en diferentes áreas. En el sector bancario, estas herramientas pueden utilizarse para analizar el comportamiento de los clientes y mejorar las estrategias empleadas durante las campañas de marketing.

En este proyecto se analizará un conjunto de datos correspondiente a una campaña de marketing telefónico de una institución bancaria. La información contiene características personales, financieras y relacionadas con los contactos realizados con los clientes. La variable de interés indica si el cliente aceptó o no contratar un depósito a plazo.

Para desarrollar el proyecto se utilizará la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), una metodología ampliamente utilizada para organizar proyectos de minería de datos. Esta metodología está conformada por seis etapas: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue.

A lo largo del proyecto se realizará la exploración y preparación de la información, se aplicarán técnicas de aprendizaje automático para construir modelos de clasificación y se evaluará su desempeño mediante diferentes métricas. Finalmente, se interpretarán los resultados obtenidos para identificar los principales patrones presentes en los datos y analizar su posible utilidad en futuras campañas de marketing bancario.

2. Objetivos

2.1 Objetivo general

Desarrollar un proyecto de minería de datos mediante la metodología CRISP-DM para analizar una campaña de marketing bancario y construir modelos de clasificación capaces de predecir si un cliente contratará un depósito a plazo a partir de sus características personales, financieras y de contacto.

2.2 Objetivos específicos

- Explorar y comprender las características principales de la base de datos Bank Marketing.
- Identificar posibles problemas de calidad en los datos, como valores faltantes, registros duplicados o valores atípicos.
- Preparar y transformar los datos para que puedan ser utilizados en modelos de aprendizaje automático.
- Construir modelos de clasificación para predecir la contratación de un depósito a plazo.
- Evaluar el desempeño de los modelos mediante métricas de clasificación y herramientas gráficas.
- Interpretar los resultados obtenidos e identificar patrones relevantes en el comportamiento de los clientes.
- Documentar el proceso completo siguiendo las etapas de la metodología CRISP-DM.

3. Metodología

3.1 CRISP-DM

La metodología que utilizaremos será CRISP-DM, que significa *Cross-Industry Standard Process for Data Mining*.

El proyecto se desarrollará mediante las siguientes seis fases:

Fase	Descripción
1. Comprensión del negocio	Se define el problema, los objetivos y lo que se busca obtener del análisis.
2. Comprensión de los datos	Se explora la estructura, características y calidad de la información.
3. Preparación de los datos	Se limpian, transforman y seleccionan los datos necesarios para el modelado.
4. Modelado	Se aplican técnicas de aprendizaje automático para construir los modelos.
5. Evaluación	Se analiza el desempeño de los modelos y se verifica si cumplen los objetivos planteados.
6. Despliegue	Se interpretan los resultados y se plantea cómo podrían utilizarse en un contexto real.

La metodología es iterativa, por lo que durante el proyecto puede ser necesario regresar a una etapa anterior cuando los resultados obtenidos indiquen que deben realizarse modificaciones en los datos o en los modelos.

3.2 base de datos

La base de datos utilizada en este proyecto es Bank Marketing, disponible en el UCI Machine Learning Repository. Los datos corresponden a campañas de marketing directo realizadas mediante llamadas telefónicas por una institución bancaria portuguesa.

3.3 Características generales

La versión utilizada corresponde al archivo bank-full.csv, que contiene:

- 45,211 registros
- 17 variables
- 16 variables predictoras
- 1 variable objetivo
- Problema de clasificación binaria
- Variables de tipo numérico, categórico y binario.
- La base no presenta valores faltantes según la documentación oficial del conjunto de datos.

El objetivo del conjunto de datos es predecir si un cliente aceptará contratar un depósito a plazo después de haber sido contactado durante una campaña de marketing.

3.4 Descripción de las variables

Variable	Tipo	Descripción
age	Numérica	Edad del cliente
job	Categórica	Tipo de ocupación
marital	Categórica	Estado civil
education	Categórica	Nivel educativo
default	Binaria	Si tiene crédito en incumplimiento
balance	Numérica	Saldo promedio anual en euros
housing	Binaria	Si tiene préstamo hipotecario
loan	Binaria	Si tiene préstamo personal

contact	Categórica	Tipo de medio utilizado para contactar al cliente
day	Numérica	Día del último contacto
month	Categórica	Mes del último contacto
duration	Numérica	Duración del último contacto, en segundos
campaign	Numérica	Número de contactos realizados durante la campaña actual
pdays	Numérica	Días transcurridos desde el contacto de una campaña anterior
previous	Numérica	Número de contactos realizados antes de la campaña actual
poutcome	Categórica	Resultado de la campaña de marketing anterior
y	Binaria	Indica si el cliente contrató el depósito a plazo

La variable y será utilizada como variable objetivo del proyecto. Sus categorías son yes y no.

3.5 Variable objetivo

La variable objetivo es y, debido a que representa el resultado de la campaña de marketing:

- yes: el cliente aceptó contratar el depósito a plazo.
- no: el cliente no contrató el depósito a plazo.

Por lo tanto, el proyecto corresponde a un problema de clasificación binaria, donde se utilizarán las características disponibles de los clientes para construir modelos capaces de predecir esta variable.

3.6 Fuente de los datos

Los datos fueron obtenidos del UCI Machine Learning Repository. El conjunto fue desarrollado por Sérgio Moro, Paulo Rita y Pedro Cortez y está asociado con el estudio sobre la predicción del éxito de campañas de telemarketing bancario.

4. Comprensión de los datos

4.1 Dimensiones de la base

La base contiene **45,211 registros y 17 variables**. Esto confirma que se está trabajando con el archivo bank-full.csv.

Las variables disponibles son:

age, job, marital, education, default, balance, housing, loan, contact, day, month, duration, campaign, pdays, previous, poutcome y y.

4.2 Estructura de los datos

La variable age es de tipo entero y representa la edad del cliente. También son numéricas balance, day, duration, campaign, pdays y previous.

Las variables job, marital, education, default, housing, loan, contact, month, poutcome y y aparecen inicialmente como variables de tipo carácter.

La variable y será nuestra **variable objetivo**, ya que indica si el cliente aceptó o no el producto ofrecido.

4.3 Estadísticos descriptivos

A partir del resumen obtenido se observa que:

- La edad promedio de los clientes es de **40.94 años**.
- La edad mínima es de **18 años** y la máxima de **95 años**.
- El saldo bancario promedio es de aproximadamente **1,362 euros**.
- El saldo mínimo registrado es de **−8,019 euros**, mientras que el máximo alcanza **102,127 euros**.
- La duración promedio de las llamadas es de aproximadamente **258.2 segundos**.
- El número promedio de contactos durante la campaña es de **2.764**.
- pdays presenta una media de **40.2 días**, aunque su mediana es −1, valor que representa que no hubo un contacto previo registrado para muchos clientes.
- previous tiene una media de **0.58 contactos anteriores**.

4.4 Valores faltantes

El resultado de:

colSums(is.na(bank))

mostró **0 valores faltantes en las 17 variables**.

Por lo tanto, no será necesario realizar una imputación de valores NA durante la preparación de los datos.

Importante: que no haya NA no significa que no existan valores especiales. Por ejemplo, unknown y -1 aparecen en algunas variables y tendremos que analizarlos durante la preparación.

4.5 Registros duplicados

El resultado fue:

[1] 0

Por lo tanto, **no se encontraron registros duplicados** en la base de datos.

4.6 Distribución de la variable objetivo

La variable y presenta:

Resultado	Frecuencia	Porcentaje
No	39,922	88.30 %
Yes	5,289	11.70 %
Total	**45,211**	**100 %**

Se observa una **distribución desbalanceada** de la variable objetivo. La categoría no representa el 88.30 % de los registros, mientras que yes representa únicamente el 11.70 %. Esta característica deberá considerarse posteriormente durante la etapa de **modelado y evaluación**, ya que una métrica como Accuracy podría resultar poco representativa si se analiza de manera aislada.

5. Preparación de los datos

5.1 Análisis de variables categóricas

Los resultados muestran que la mayoría de las variables categóricas presentan una distribución razonable entre sus categorías. Sin embargo, se identificaron valores unknown en algunas variables.

Los valores unknown encontrados fueron:

Variable	unknown	Porcentaje aprox.
job	288	0.64 %
education	1,857	4.11 %
contact	13,020	28.80 %
poutcome	36,959	81.75 %

5.2 Tratamiento de pdays

Encontramos:

FALSE TRUE

8257 36954

Es decir, **36,954 clientes (81.74 %) tienen pdays = -1**.

En esta base, -1 representa que el cliente **no fue contactado previamente** durante una campaña anterior.

Por lo tanto, tampoco vamos a eliminar estos registros.

5.3 Variables numéricas y valores extremos

Los resultados muestran diferencias importantes en las escalas:

- age: 18–95 años.
- balance: −8,019 a 102,127 euros.
- duration: 0–4,918 segundos.
- campaign: 1–63 contactos.
- pdays: −1–871 días.
- previous: 0–275 contactos.

En particular, balance, duration, campaign y previous presentan valores muy dispersos.

5.4 Lo que ya tenemos decidido

Situación	Decisión
Valores NA	No existen
Duplicados	No existen
unknown	**Conservar**
pdays = -1	**Conservar**
Valores extremos	**No eliminar automáticamente**
Variables categóricas	Transformar posteriormente
Variable y	Variable objetivo

En esta etapa se realizaron las transformaciones necesarias para preparar la base de datos para el modelado. Las variables categóricas fueron convertidas a factores en R, incluyendo job, marital, education, default, housing, loan, contact, month, poutcome y la variable objetivo y.

No se eliminaron los valores unknown ni los valores -1 de la variable pdays, debido a que representan información sobre la disponibilidad de datos y el historial de contacto de los clientes.

Posteriormente, la base de datos se dividió en dos conjuntos utilizando una semilla aleatoria de 123. El 70% de los registros, correspondiente a 31,647 observaciones, se destinó al conjunto de entrenamiento, mientras que el 30%, correspondiente a 13,564 observaciones, se utilizó para prueba.

El conjunto de entrenamiento contiene 27,924 clientes que no contrataron el depósito y 3,723 que sí lo contrataron. El conjunto de prueba contiene 11,998 casos de la categoría no y 1,566 de la categoría yes. La distribución de la variable objetivo se mantiene aproximadamente constante en ambos conjuntos.

5.5 Modelado

Para la etapa de modelado se utilizó una regresión logística, debido a que la variable objetivo y es binaria y representa si el cliente contrató (yes) o no contrató (no) un depósito a plazo.

El modelo fue ajustado utilizando el conjunto de entrenamiento, formado por 31,647 observaciones. Se incluyeron las variables personales, financieras y relacionadas con la campaña de marketing disponibles en la base de datos.

Los resultados muestran que varias variables presentan una asociación estadísticamente significativa con la probabilidad de contratación. Entre ellas destacan la duración del contacto (duration), la tenencia de un crédito hipotecario (housing), el tipo de contacto (contact), el mes de contacto y el resultado de campañas anteriores (poutcome).

La variable duration presenta un coeficiente positivo y altamente significativo ($p < 0.001$), indicando una relación positiva entre la duración de la llamada y la probabilidad estimada de contratación. También se observa un efecto significativo de poutcome, particularmente en la categoría success.

El modelo presentó una deviance nula de 22,925 y una deviance residual de 15,090, además de un AIC de 15,176. Estos resultados muestran una mejora del modelo respecto al modelo nulo y permiten continuar con la evaluación de su capacidad de clasificación sobre los datos de prueba.

5.6 Evaluación

El modelo de regresión logística fue evaluado utilizando el 30% de los datos reservado para prueba, correspondiente a 13,564 observaciones. Se utilizó un punto de corte de 0.50 para convertir las probabilidades estimadas en las categorías yes y no.

La matriz de confusión mostró 11,691 casos clasificados correctamente como no y 546 casos clasificados correctamente como yes. Por otro lado, 307 clientes fueron clasificados incorrectamente como yes cuando realmente pertenecían a la categoría no, mientras que 1,020 clientes que sí contrataron el depósito fueron clasificados como no.

La exactitud obtenida fue de 90.22%, lo que indica que el modelo clasificó correctamente aproximadamente nueve de cada diez observaciones. La especificidad fue de 97.44%, mostrando una alta capacidad para identificar correctamente a los clientes que no contrataron el depósito.

Sin embargo, la sensibilidad fue de 34.87%, lo que indica que el modelo identificó correctamente aproximadamente un tercio de los clientes que sí contrataron el depósito. Este resultado debe interpretarse considerando que la variable objetivo presenta un desbalance importante, ya que la categoría no representa la mayoría de las observaciones.

5.7 Despliegue

Como etapa final de CRISP-DM, se propone utilizar el modelo de regresión logística como una herramienta de apoyo para estimar la probabilidad de que un cliente contrate un depósito a plazo.

El modelo podría utilizarse sobre nuevos registros de clientes para obtener una probabilidad estimada de contratación y apoyar la selección de clientes para futuras campañas de marketing. Sin embargo, debido a la sensibilidad relativamente baja obtenida, sus predicciones deben utilizarse como apoyo y no como único criterio para tomar decisiones.

El modelo también podría actualizarse con información de nuevas campañas para evaluar si su capacidad predictiva se mantiene y realizar ajustes cuando sea necesario.

6. Resultados

El análisis realizado mediante la metodología CRISP-DM permitió construir un modelo de regresión logística para predecir la contratación de un depósito a plazo a partir de las características de los clientes y de las variables relacionadas con la campaña de marketing.

La base de datos utilizada estuvo conformada por 45,211 registros y 17 variables. Durante la exploración se identificó que no existían valores faltantes registrados como NA ni registros duplicados. La variable objetivo presentó un desbalance importante: 39,922 clientes no contrataron el depósito, mientras que 5,289 sí lo contrataron, representando el 88.30% y 11.70% de los registros, respectivamente.

Para el modelado, los datos fueron divididos en 70% para entrenamiento y 30% para prueba. La regresión logística presentó una deviance nula de 22,925 y una deviance residual de 15,090, con un AIC de 15,176. Entre las variables que mostraron relaciones estadísticamente significativas con la respuesta destacaron la duración del contacto, la variable housing, el tipo de contacto, algunos meses de la campaña y el resultado de campañas anteriores.

Al evaluar el modelo sobre los datos de prueba se obtuvo una exactitud de **90.22%**, una especificidad de **97.44%** y una sensibilidad de **34.87%**. La matriz de confusión mostró que el modelo clasificó correctamente 11,691 casos de clientes que no contrataron y 546 casos de clientes que sí contrataron.

7. Conclusiones

El proyecto permitió aplicar la metodología CRISP-DM a un problema de clasificación utilizando la base de datos Bank Marketing. Se realizó el proceso completo desde la comprensión del problema y exploración de los datos hasta la construcción y evaluación de un modelo de regresión logística.

La base presentó una distribución desbalanceada de la variable objetivo, situación que influyó en el desempeño del modelo. La regresión logística obtuvo una exactitud de 90.22% y una especificidad de 97.44%, pero una sensibilidad de 34.87%, mostrando que el modelo identifica con mayor facilidad a los clientes que no contratan el depósito que a aquellos que sí lo hacen.

El análisis también permitió identificar variables relacionadas significativamente con la respuesta, entre las que destacan la duración del contacto, el tipo de contacto, el mes de la campaña y los resultados de campañas anteriores.

En conclusión, el modelo constituye una herramienta útil para analizar los patrones presentes en los datos y puede servir como punto de partida para apoyar futuras campañas de marketing. Sin embargo, sería conveniente realizar posteriormente técnicas orientadas al desbalance de clases y comparar diferentes modelos para mejorar la identificación de los clientes que sí tienen una respuesta positiva.

8. Referencias bibliográficas

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS.

Moro, S., Cortez, P., & Rita, P. (2014). A data-driven approach to predict the success of bank telemarketing. *Decision Support Systems, 62*, 22–31. https://doi.org/10.1016/j.dss.2014.03.001

UCI Machine Learning Repository. (2014). *Bank Marketing* [Dataset]. University of California, Irvine, School of Information and Computer Sciences. https://archive.ics.uci.edu/dataset/222/bank+marketing

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3rd ed.). Wiley.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2nd ed.). Springer.