UNIVERSIDAD VERACRUZANA

TDSP: DESEMPEÑO ACADÉMICO DE LOS ALUMNOS.

MARÍA FERNANDA ARELLANO PÉREZ

DAIRA LISSET LANDA APOLINAR

JOSÉ ANTONIO HERNÁNDEZ CARMONA

INDICE

INTRODUCCION.....1

ROLES DEL EQUIPO.....1.1

COMPRENSIÓN DEL NEGOCIO O PROBLEMA.....2

ADQUISICIÓN Y COMPRENSIÓN DE LOS DATOS.....3

EXPLORACIÓN DE LOS DATOS.....4

ANÁLISIS EXPLORATORIO.....5

PREPARACIÓN DE LOS DATOS.....6

SELECCIÓN DE VARIABLES.....7

DIVISIÓN DE LOS DATOS.....8

MODELADO.....9

ANÁLISIS DE LOS COEFICIENTES.....10

EVALUACIÓN DEL MODELO.....11

COMPARACIÓN ENTRE VALORES REALES Y PREDICHOS.....12

ANÁLISIS DE LOS RESIDUOS.....13

IMPLEMENTACIÓN.....14

ACEPTACION.....15

RESULTADOS.....16

LIMITACIONES.....17

CONCLUSIONES.....18

REFERENCIAS.....19

ANEXO DEL CODIGO.....20

1. INTRODUCCIÓN

La ciencia de datos permite analizar grandes cantidades de información para identificar patrones y generar modelos capaces de apoyar la toma de decisiones. Para desarrollar proyectos de este tipo existen diferentes metodologías, entre ellas el **Team Data Science Process (TDSP)**, propuesta por Microsoft.

En este trabajo se aplica la metodología TDSP a un conjunto de datos relacionado con el **rendimiento académico de estudiantes**. El objetivo es analizar diferentes características personales, familiares, sociales y académicas de los estudiantes y desarrollar un modelo que permita predecir su calificación final.

El conjunto de datos utilizado corresponde a **Student Performance**, disponible en el repositorio UCI Machine Learning Repository. La base contiene información de estudiantes de educación secundaria y variables relacionadas con su desempeño académico.

1.1Roles del equipo

1.1.1 Propietario del producto

Jose Antonio definió la visión y el problema: predecir la calificación final a partir de las características, definió los requisitos. Redactó la pregunta de investigación, el objetivo general, los siete objetivos específicos y los criterios de éxito. Trabajo para asegurar que el equipo aporte valor a la organización y revisó si lo entregado cumplía esos criterios.

- Responsabilidades: priorizar requisitos según objetivos de y necesidades discutidas, coordinar equipos multifuncionales, comunicar avances, mantener la ruta y verificar que las soluciones cumplan su propósito.

1.1. 2Científico de datos

Jose Antonio eligió la regresión lineal múltiple, seleccionó las variables predictoras y construyó el modelo. También interpretó los coeficientes, analizó los residuos.

- Responsabilidades: desarrollo los modelos estadísticos, analizo los datos, colaboro en la preparación de datos y comunico los hallazgos con el equipo.

1.1.3. Ingeniero de datos

Daira Landa es responsable de la recopilación, almacenamiento y procesamiento de datos. Construye y mantiene la infraestructura que permite al equipo trabajar con grandes cantidades de datos de alta calidad. Dejó los datos listos para modelar y guardó los resultados en archivos CSV.

- Responsabilidades: mantener la infraestructura y garantizar la calidad, precisión y coherencia de los datos.

1.1.4. Analista de datos

Daira Landa recopiló, procesó y analizó estadísticamente el conjunto de datos para comunicar información a quienes toman decisiones. Hizo la parte descriptiva generó los gráficos exploratorios y la matriz de correlación.

- Responsabilidades: preprocesar los datos, identificar patrones y tendencias, y desarrollar informes.

1.1.5. Ingeniero de aprendizaje automático.

Maria Fernanda construye y despliega modelos de ML en producción. Entrenó el modelo final con todos los datos y armó el flujo de predicción

- Responsabilidades: desarrollar y desplegar modelos escalables, mantener la infraestructura, implementar flujos de trabajo reproducibles y monitorizar el rendimiento de los modelos.

1.1.6. Experto en procesos

Lorena garantiza que el equipo trabaje eficazmente y adopte principios ágiles. Se aseguró de que el trabajo siguiera las etapas de TDSP en orden. Estructuró el documento y el código por etapas y lo dejó reproducible. También verificó que cada etapa quedara documentada.

- Responsabilidades: guiar al equipo en prácticas ágiles, eliminar impedimentos y escalar riesgos.

1.1.7. Gestor de proyecto

Maria Fernanda trabaja para asegurar una ejecución exitosa definió el alcance, coordinó tiempos, y documentó las limitaciones. También armó el índice, las referencias y el anexo.

- Responsabilidades: elaborar planes de proyecto (tiempo), coordinar tareas, gestionar expectativas de los interesados.

1.1.8. Jefe de equipo

Lorena asegura que cumpla sus objetivos y gestiona el rendimiento individual. Lidera el reclutamiento, la formación y tareas administrativas. Suele supervisar a científicos, analistas e ingenieros. Supervisó que todo el trabajo fuera coherente con el objetivo y revisó la calidad final. Validó que las conclusiones coincidieran con los resultados y que las cifras fueran consistentes en todo el documento. Aprobó la entrega.

- Responsabilidades: liderar y mentorizar, identificar oportunidades de ciencia de datos, gestionar personal y equipo.

2. COMPRENSIÓN DEL NEGOCIO O PROBLEMA

2.1 Planteamiento del problema

El rendimiento académico de un estudiante puede estar relacionado con diversos factores, como el tiempo dedicado al estudio, las ausencias, las calificaciones obtenidas anteriormente, las reprobaciones, el apoyo familiar y algunas características personales y sociales.

Por esta razón, resulta de interés analizar si las características disponibles en los datos permiten explicar y predecir la calificación final de los estudiantes.

2.2 Pregunta de investigación

¿Es posible predecir la calificación final de un estudiante utilizando sus características personales, familiares, sociales y académicas?

2.3 Objetivo general

Desarrollar un modelo predictivo para estimar la calificación final de estudiantes a partir de variables personales, familiares, sociales y académicas, siguiendo las etapas de la metodología TDSP.

2.4 Objetivos específicos

- Explorar y comprender el conjunto de datos.
- Identificar las características de los estudiantes.
- Analizar las variables relacionadas con la calificación final.
- Preparar los datos para la construcción del modelo.
- Desarrollar un modelo predictivo.
- Evaluar el desempeño del modelo mediante métricas estadísticas.
- Interpretar los resultados obtenidos.

2.5 Criterios de éxito

El proyecto se considerará satisfactorio si:

- Los datos pueden ser cargados y preparados correctamente.
- Se identifican variables relacionadas con el rendimiento académico.
- Se obtiene un modelo capaz de realizar predicciones.
- El modelo presenta métricas de evaluación que permitan determinar su desempeño.
- Los resultados pueden ser interpretados y comunicados de manera clara.

3. ADQUISICIÓN Y COMPRENSIÓN DE LOS DATOS

3.1 Fuente de los datos

Se utilizó el conjunto de datos **Student Performance**, disponible en **UCI Machine Learning Repository**.

El conjunto contiene información sobre estudiantes de educación secundaria y variables relacionadas con su desempeño académico, características familiares, sociales y escolares.

La fuente de los datos es:

UCI Machine Learning Repository – Student Performance

https://archive.ics.uci.edu/dataset/320/student+performance

Para este proyecto se utilizó el archivo:

student-mat.csv

correspondiente al desempeño de los estudiantes en la asignatura de matemáticas.

3.2 Descripción de los datos

El archivo contiene información de **395 estudiantes y 33 variables**.

Entre las variables más importantes se encuentran:

Variable	Descripción
school	Escuela del estudiante
sex	Sexo
age	Edad
address	Tipo de zona de residencia

famsize	Tamaño de la familia
Pstatus	Situación de los padres
Medu	Educación de la madre
Fedu	Educación del padre
studytime	Tiempo dedicado al estudio
failures	Reprobaciones anteriores
schoolsup	Apoyo educativo escolar
famsup	Apoyo educativo familiar
internet	Acceso a Internet
absences	Número de ausencias
G1	Calificación del primer periodo
G2	Calificación del segundo periodo
G3	Calificación final

La variable **G3** fue utilizada como variable objetivo.

4. EXPLORACIÓN DE LOS DATOS

Una vez obtenida la base, se realizó una exploración inicial para conocer su estructura, dimensiones, tipos de variables y calidad de los datos.

El conjunto de datos contiene:

- **395 observaciones**
- **33 variables**
- **0 valores faltantes**
- **0 registros duplicados**

La edad de los estudiantes se encuentra entre **15 y 22 años**, con una media de aproximadamente **16.7 años**.

La variable objetivo **G3**, correspondiente a la calificación final, presenta los siguientes resultados:

- Mínimo: **0**
- Primer cuartil: **8**
- Mediana: **11**
- Media: **10.4152**
- Tercer cuartil: **14**
- Máximo: **20**
- Desviación estándar: **4.5814**

Esto indica que la calificación final promedio de los estudiantes es aproximadamente **10.42 puntos**.

La exploración también permitió identificar que no existen valores faltantes en ninguna de las 33 variables, por lo que no fue necesario realizar procedimientos de imputación.

5. ANÁLISIS EXPLORATORIO

En esta etapa se analizaron las relaciones entre la calificación final y algunas variables explicativas.

5.1 Distribución de la calificación final

La calificación final presenta valores desde 0 hasta 20, con una mediana de 11 y una media de aproximadamente 10.42.

5.2 Relación entre G1, G2 y G3

Se analizaron las relaciones entre las calificaciones de los periodos anteriores y la calificación final.

Las correlaciones obtenidas fueron:

Variables	Correlación
G1 y G3	**0.8015**
G2 y G3	**0.9049**
G1 y G2	**0.8521**

La relación entre **G2 y G3** fue particularmente alta, con una correlación de **0.9049**.

6. PREPARACIÓN DE LOS DATOS

La siguiente etapa del TDSP consistió en preparar los datos para el modelado.

Se verificaron:

- Valores faltantes.
- Valores duplicados.
- Tipos de variables.
- Variables categóricas.
- Variables numéricas.
- Variables que podían utilizarse como predictores.

No se encontraron valores faltantes:

Total de valores faltantes = 0

Tampoco se encontraron registros duplicados:

Registros duplicados = 0

Para el modelo se transformaron las variables categóricas sex, schoolsup, famsup e internet a factores.

7. SELECCIÓN DE VARIABLES

Para la construcción del modelo se seleccionaron las siguientes variables predictoras:

- age
- sex
- studytime
- failures
- schoolsup
- famsup
- internet
- absences
- G1
- G2

La variable objetivo fue:

G3

Por lo tanto, el modelo busca estimar la calificación final utilizando las características personales, académicas y sociales seleccionadas.

8. DIVISIÓN DE LOS DATOS

Los datos fueron divididos utilizando una proporción de:

- **80 % para entrenamiento**
- **20 % para prueba**

Se utilizó una semilla aleatoria de **123** para garantizar que la división pudiera reproducirse.

Los resultados fueron:

Conjunto	Observaciones
Entrenamiento	**316**
Prueba	**79**
Total	**395**

El conjunto de entrenamiento se utilizó para construir el modelo, mientras que el conjunto de prueba se reservó para evaluar su capacidad predictiva sobre datos que no fueron utilizados durante el entrenamiento.

9. MODELADO

Para este proyecto se utilizó un modelo de **regresión lineal múltiple**, debido a que la variable objetivo G3 es numérica.

El modelo utilizado fue:

G3 ~ age + sex + studytime + failures + schoolsup + famsup + internet + absences + G1 + G2

El modelo obtenido presentó los siguientes resultados:

- **$R^2 = 0.8493$**
- **R^2 ajustado = 0.8444**
- **Error estándar residual = 1.775**
- **F = 171.9**
- **$p < 2.2 \times 10^{-16}$**

El valor de R^2 indica que aproximadamente el **84.93 % de la variabilidad de G3** fue explicada por las variables incluidas en el modelo de entrenamiento.

El valor p asociado a la prueba F indica que, en conjunto, existe evidencia estadística de una relación entre las variables predictoras y la calificación final.

10. ANÁLISIS DE LOS COEFICIENTES

Los principales coeficientes obtenidos fueron:

Variable	Coeficiente	Valor p
age	-0.2290	0.0098
sexM	0.1941	0.3738
studytime	-0.1698	0.1981
failures	-0.4012	0.0132
schoolsupyes	0.0509	0.8814
famsupyes	0.2483	0.2484
internetyes	-0.2528	0.3696
absences	0.0406	0.0016
G1	0.1583	0.0082
G2	**0.9665**	**$< 2 \times 10^{-16}$**

Las variables estadísticamente significativas al nivel de 5 % fueron:

- Edad.
- Reprobaciones anteriores.
- Ausencias.
- G1.
- G2.

La variable con mayor evidencia estadística dentro del modelo fue **G2**.

Su coeficiente fue **0.9665**, lo que indica que, manteniendo constantes las demás variables, un aumento de un punto en G2 se asocia con un aumento aproximado de **0.97 puntos en la calificación final estimada**.

11. EVALUACIÓN DEL MODELO

Después de construir el modelo, se realizaron predicciones sobre las **79 observaciones del conjunto de prueba**.

Las métricas obtenidas fueron:

Métrica	Resultado
RMSE	**2.3784**
MAE	**1.6338**
R^2	**0.7600**

11.1 RMSE

El RMSE obtenido fue de **2.3784**.

Este resultado indica que el error de predicción, considerando con mayor peso los errores grandes, fue de aproximadamente 2.38 puntos.

11.2 MAE

El MAE obtenido fue de **1.6338**.

Esto significa que, en términos absolutos, las predicciones presentaron un error promedio de aproximadamente **1.63 puntos** respecto a las calificaciones reales.

11.3 R^2

El R^2 obtenido sobre el conjunto de prueba fue de **0.7600**.

Por lo tanto, aproximadamente el **76 % de la variabilidad de las calificaciones finales del conjunto de prueba** fue explicada por el modelo.

El resultado de prueba es inferior al R^2 obtenido durante el entrenamiento (0.8493), lo cual es esperable porque el conjunto de prueba contiene observaciones que no fueron utilizadas para ajustar el modelo.

12. COMPARACIÓN ENTRE VALORES REALES Y PREDICHOS

Se realizó una comparación entre las calificaciones reales y las predicciones generadas por el modelo.

La correlación entre ambos valores fue:

0.8744

Este resultado muestra una relación positiva considerable entre las calificaciones reales y las estimadas por el modelo.

13. ANÁLISIS DE LOS RESIDUOS

Para evaluar el comportamiento de los errores del modelo se analizaron los residuos mediante gráficos de diagnóstico.

También se aplicó la prueba de Shapiro-Wilk para evaluar la normalidad de los residuos.

El resultado fue:

- **W = 0.76135**
- **$p < 2.2 \times 10^{-16}$**

Debido a que el valor p es menor que 0.05, se rechaza la hipótesis de normalidad de los residuos.

Por lo tanto, los residuos **no presentan una distribución normal de acuerdo con la prueba de Shapiro-Wilk**.

Este resultado representa una limitación del modelo y debe considerarse al interpretar los resultados.

14. IMPLEMENTACIÓN

Una vez evaluado el modelo, se planteó su posible utilización para realizar predicciones sobre nuevos estudiantes.

El proceso puede representarse como:

Datos del estudiante → Procesamiento → Modelo predictivo → Calificación estimada

Como ejemplo, se realizó una predicción para un estudiante con las siguientes características:

- Edad: 17 años.
- Sexo: masculino.
- Tiempo de estudio: 2.
- Reprobaciones anteriores: 0.
- Sin apoyo escolar.
- Con apoyo familiar.
- Con acceso a Internet.
- Ausencias: 5.
- G1: 12.
- G2: 13.

El modelo final estimó:

Calificación final = 12.90

El intervalo de predicción obtenido fue aproximadamente:

9.14 – 16.66

Este resultado representa una estimación del posible valor de la calificación final bajo las características especificadas.

El modelo debe considerarse una herramienta de apoyo para el análisis y no un mecanismo definitivo para determinar el desempeño de un estudiante.

15. ACEPTACIÓN

De acuerdo con TDSP, los resultados fueron revisados para determinar si cumplen con los objetivos establecidos inicialmente.

El proyecto permitió:

- Cargar y comprender correctamente el conjunto de datos.
- Identificar las características de los estudiantes.
- Analizar variables relacionadas con la calificación final.
- Preparar los datos para el modelado.
- Construir un modelo predictivo.
- Evaluar el modelo mediante RMSE, MAE y R^2.
- Analizar los coeficientes y residuos.
- Realizar predicciones sobre nuevos datos.

El modelo obtuvo un **R^2 de 0.7600 sobre el conjunto de prueba**, un **MAE de 1.6338** y un **RMSE de 2.3784**, por lo que fue posible generar predicciones de la calificación final con un nivel de error cuantificable.

Sin embargo, la prueba de normalidad de los residuos mostró una limitación que debe considerarse al interpretar los resultados.

16. RESULTADOS

Los resultados finales del proyecto fueron los siguientes:

Elemento	Resultado
Estudiantes	**395**
Variables originales	**33**
Datos de entrenamiento	**316**
Datos de prueba	**79**
R^2 entrenamiento	**0.8493**
R^2 prueba	**0.7600**
RMSE	**2.3784**
MAE	**1.6338**
Correlación real-predicho	**0.8744**
Media de G3	**10.4152**
Mediana de G3	**11**
Desviación estándar de G3	**4.5814**

Los resultados muestran que el modelo tiene una capacidad considerable para explicar y predecir la calificación final.

Las calificaciones G1 y G2 mostraron las relaciones más fuertes con G3. Particularmente, G2 presentó una correlación de **0.9049** con la calificación final.

17. LIMITACIONES

El proyecto presenta algunas limitaciones.

Primero, los datos corresponden a un conjunto específico de estudiantes, por lo que los resultados no necesariamente representan a todos los estudiantes de otras escuelas, regiones o países.

Además, algunas variables utilizadas para predecir G3, particularmente **G1 y G2**, corresponden a calificaciones obtenidas durante el mismo proceso académico. Por ello, aunque pueden mejorar considerablemente la predicción, su utilización debe considerarse al interpretar el modelo.

Otra limitación encontrada durante la evaluación fue que los residuos no presentaron normalidad de acuerdo con la prueba de Shapiro-Wilk.

También debe considerarse que la relación observada entre las variables no necesariamente implica causalidad.

Finalmente, un modelo estadístico no puede incorporar todos los factores que influyen en el rendimiento académico de un estudiante.

18. CONCLUSIONES

La metodología **Team Data Science Process (TDSP)** permitió organizar de manera estructurada un proyecto de ciencia de datos, comenzando con la definición del problema y continuando con la adquisición, exploración y preparación de los datos, el desarrollo del modelo, su evaluación y la generación de predicciones.

En este proyecto se analizó el conjunto de datos **Student Performance**, compuesto por 395 estudiantes y 33 variables. La variable objetivo seleccionada fue la calificación final **G3**, mientras que diferentes características personales, académicas y sociales fueron utilizadas como variables predictoras.

El modelo de regresión lineal múltiple obtuvo un **R^2 de 0.8493 en los datos de entrenamiento** y un **R^2 de 0.7600 en los datos de prueba**. Además, presentó un **RMSE de 2.3784** y un **MAE de 1.6338**, mientras que la correlación entre los valores reales y predichos fue de **0.8744**.

Los resultados muestran que el modelo fue capaz de explicar una parte importante de la variabilidad de las calificaciones y generar predicciones con un error promedio absoluto de aproximadamente 1.63 puntos.

Entre las variables analizadas, las calificaciones anteriores G1 y G2 mostraron una relación particularmente importante con la calificación final. G2 presentó una correlación de 0.9049 con G3 y un coeficiente de 0.9665 dentro del modelo de entrenamiento.

Sin embargo, el análisis de los residuos mostró que no se cumple el supuesto de normalidad de acuerdo con la prueba de Shapiro-Wilk. Esta situación constituye una limitación que debe tomarse en cuenta al interpretar los resultados.

Asimismo, el uso de G1 y G2 implica que el modelo está diseñado principalmente para realizar predicciones cuando ya se dispone de las calificaciones de periodos anteriores. Esto limita su utilización para predecir el rendimiento de un estudiante antes de que haya realizado dichas evaluaciones.

En conclusión, el proyecto permitió aplicar de manera práctica las diferentes etapas de la metodología TDSP y desarrollar un modelo de regresión capaz de generar estimaciones de la calificación final de los estudiantes, además de identificar las principales variables relacionadas con el comportamiento de dicha calificación.

19. REFERENCIA

Referencias

Cortez, P., & Silva, A. (2008). *Using Data Mining to Predict Secondary School Student Performance*. 5th FUture Business Technology Conference, Porto, Portugal.

UCI Machine Learning Repository. (s. f.). *Student Performance*. https://archive.ics.uci.edu/dataset/320/student+performance

Microsoft. (s. f.). *Team Data Science Process (TDSP)*. Microsoft Learn.

Universidad Veracruzana. (s. f.). *Material de clase sobre Team Data Science Process (TDSP)*. Eminus 4. https://eminus.uv.mx/eminus4/page/course/content/lienzo

R Core Team. (2026). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. https://www.R-project.org/

ANEXO CODIGO

```
# 1. LIMPIAR EL ENTORNO

rm(list = ls())

# 2. INSTALAR/CARGAR PAQUETES

library(ggplot2)

library(dplyr)

library(corrplot)

# 3. ADQUISICIÓN DE LOS DATOS

datos <- read.csv(

 "C:/Users/joseh/OneDrive/Documentos/student-mat.csv",

 sep = ";",

 header = TRUE

)

# 4. COMPRENSIÓN Y EXPLORACIÓN INICIAL DE LOS DATOS

# Primeras observaciones

head(datos)

# Últimas observaciones

tail(datos)

# Dimensiones del conjunto de datos

dim(datos)
```

```
# Nombres de las variables
names(datos)
# Estructura de los datos
str(datos)
# Resumen estadístico
summary(datos)
# 5. CALIDAD DE LOS DATOS
# Cantidad de valores faltantes por variable
colSums(is.na(datos))
# Cantidad total de valores faltantes
sum(is.na(datos))
# Cantidad de registros duplicados
sum(duplicated(datos))
# 6. COMPRENSIÓN DE LA VARIABLE OBJETIVO
# Variable objetivo: G3
# G3 representa la calificación final del estudiante.
summary(datos$G3)
# Media
mean(datos$G3)
# Mediana
median(datos$G3)
# Desviación estándar
sd(datos$G3)
# Mínimo
min(datos$G3)
# Máximo
max(datos$G3)
# 7. HISTOGRAMA DE LA CALIFICACIÓN FINAL
ggplot(datos, aes(x = G3)) +
 geom_histogram(
  binwidth = 1,
  color = "black",
  fill = "steelblue"
 ) +
 labs(
```

```
  title = "Distribución de la calificación final",
  x = "Calificación final (G3)",
  y = "Número de estudiantes"
 ) +
 theme_minimal()
# 8. RELACIÓN ENTRE TIEMPO DE ESTUDIO Y CALIFICACIÓN FINAL
ggplot(datos, aes(x = factor(studytime), y = G3)) +
 geom_boxplot(fill = "lightblue") +
 labs(
  title = "Calificación final según tiempo de estudio",
  x = "Tiempo de estudio",
  y = "Calificación final (G3)"
 ) +
 theme_minimal()
# 9. RELACIÓN ENTRE AUSENCIAS Y CALIFICACIÓN FINAL
ggplot(datos, aes(x = absences, y = G3)) +
 geom_point() +
 geom_smooth(
  method = "lm",
  se = TRUE
 ) +
 labs(
  title = "Relación entre ausencias y calificación final",
  x = "Número de ausencias",
  y = "Calificación final (G3)"
 ) +
 theme_minimal()
# 10. RELACIÓN ENTRE G1 Y G3
ggplot(datos, aes(x = G1, y = G3)) +
 geom_point() +
 geom_smooth(
  method = "lm",
  se = TRUE
 ) +
 labs(
```

```
  title = "Relación entre G1 y G3",
  x = "Primera calificación (G1)",
  y = "Calificación final (G3)"
 ) +
 theme_minimal()
# 11. RELACIÓN ENTRE G2 Y G3
ggplot(datos, aes(x = G2, y = G3)) +
 geom_point() +
 geom_smooth(
  method = "lm",
  se = TRUE
 ) +
 labs(
  title = "Relación entre G2 y G3",
  x = "Segunda calificación (G2)",
  y = "Calificación final (G3)"
 ) +
 theme_minimal()
# 12. MATRIZ DE CORRELACIÓN
variables_numericas <- datos %>%
 select(
  age,
  Medu,
  Fedu,
  studytime,
  failures,
  absences,
  G1,
  G2,
  G3
 )
matriz_cor <- cor(variables_numericas)
print(matriz_cor)
corrplot(
 matriz_cor,
```

```
  method = "color",
  type = "upper",
  addCoef.col = "black",
  tl.col = "black",
  number.cex = 0.7
)
# 13. PREPARACIÓN DE LOS DATOS PARA EL MODELO
datos_modelo <- datos %>%
  select(
    G3,
    age,
    sex,
    studytime,
    failures,
    schoolsup,
    famsup,
    internet,
    absences,
    G1,
    G2
  )
# Convertir variables categóricas a factores
datos_modelo$sex <- as.factor(datos_modelo$sex)
datos_modelo$schoolsup <- as.factor(
  datos_modelo$schoolsup
)
datos_modelo$famsup <- as.factor(
  datos_modelo$famsup
)
datos_modelo$internet <- as.factor(
  datos_modelo$internet
)
# Revisar estructura final
str(datos_modelo)
summary(datos_modelo)
```

```
# 14. DIVISIÓN DE LOS DATOS EN ENTRENAMIENTO Y PRUEBA
set.seed(123)
n <- nrow(datos_modelo)
indices_entrenamiento <- sample(
 1:n,
 size = 0.80 * n
)
datos_entrenamiento <- datos_modelo[
 indices_entrenamiento,
]
datos_prueba <- datos_modelo[
 -indices_entrenamiento,
]
# Tamaño de cada conjunto
dim(datos_entrenamiento)
dim(datos_prueba)
# 15. CONSTRUCCIÓN DEL MODELO DE REGRESIÓN LINEAL MÚLTIPLE
modelo <- lm(
 G3 ~ age +
  sex +
  studytime +
  failures +
  schoolsup +
  famsup +
  internet +
  absences +
  G1 +
  G2,
 data = datos_entrenamiento
)
# 16. RESUMEN DEL MODELO
summary(modelo)
# 17. COEFICIENTES DEL MODELO
coef(modelo)
# 18. INTERVALOS DE CONFIANZA
```

```
confint(modelo)
# 19. ANÁLISIS DE VARIANZA
anova(modelo)
# 20. PREDICCIONES SOBRE LOS DATOS DE PRUEB
predicciones <- predict(
 modelo,
 newdata = datos_prueba
)
head(predicciones)
# 21. COMPARAR VALORES REALES Y PREDICHOS
comparacion <- data.frame(
 Real = datos_prueba$G3,
 Predicho = predicciones
)
head(comparacion, 20)
# 22. ERROR RMSE

RMSE <- sqrt(
 mean(
  (datos_prueba$G3 - predicciones)^2
 )
)
RMSE
# 23. ERROR MAE
MAE <- mean(
 abs(
  datos_prueba$G3 - predicciones
 )
)
MAE
# 24. R CUADRADA SOBRE LOS DATOS DE PRUEBA
SS_res <- sum(
 (datos_prueba$G3 - predicciones)^2
)
SS_tot <- sum(
```

```
 (datos_prueba$G3 - mean(datos_prueba$G3))^2
)
R2_prueba <- 1 - (
 SS_res / SS_tot
)
R2_prueba
# 25. TABLA DE MÉTRICAS
metricas <- data.frame(
 RMSE = RMSE,
 MAE = MAE,
 R2 = R2_prueba
)
print(metricas)
# 26. GRÁFICA DE VALORES REALES VS PREDICHOS
ggplot(
 comparacion,
 aes(
  x = Real,
  y = Predicho
 )
) +
 geom_point(size = 3) +
 geom_abline(
  slope = 1,
  intercept = 0,
  linetype = "dashed"
 ) +
 labs(
  title = "Valores reales vs valores predichos",
  x = "Calificación real",
  y = "Calificación predicha"
 ) +
 theme_minimal()
# 27. RESIDUOS DEL MODELO
residuos <- residuals(modelo)
```

```
head(residuos)
# 28. HISTOGRAMA DE RESIDUOS
hist(
  residuos,
  main = "Distribución de los residuos",
  xlab = "Residuos",
  col = "lightblue",
  border = "black"
)
# 29. RESIDUOS VS VALORES AJUSTADOS
plot(
  fitted(modelo),
  residuos,
  main = "Residuos vs valores ajustados",
  xlab = "Valores ajustados",
  ylab = "Residuos"
)
abline(
  h = 0,
  lty = 2
)
# 30. GRÁFICAS DE DIAGNÓSTICO DEL MODELO
par(mfrow = c(2, 2))
plot(modelo)
par(mfrow = c(1, 1))
# 31. PRUEBA DE NORMALIDAD DE LOS RESIDUOS
shapiro.test(residuos)
# 32. CORRELACIÓN ENTRE VALORES REALES Y PREDICHOS
correlacion_real_predicho <- cor(
  datos_prueba$G3,
  predicciones
)
correlacion_real_predicho
# 33. SIGNIFICANCIA DE LOS COEFICIENTE
tabla_coeficientes <- summary(modelo)$coefficients
```

```
print(tabla_coeficientes)
# 34. MODELO FINAL UTILIZANDO TODOS LOS DATOS


modelo_final <- lm(
 G3 ~ age +
  sex +
  studytime +
  failures +
  schoolsup +
  famsup +
  internet +
  absences +
  G1 +
  G2,
 data = datos_modelo
)
summary(modelo_final)
# 35. PREDICCIÓN DE UN NUEVO ESTUDIANTE
nuevo_estudiante <- data.frame(
 age = 17,
 sex = factor(
  "M",
  levels = levels(datos_modelo$sex)
 ),
 studytime = 2,
 failures = 0,
 schoolsup = factor(
  "no",
  levels = levels(datos_modelo$schoolsup)
 ),
 famsup = factor(
  "yes",
  levels = levels(datos_modelo$famsup)
 ),
 internet = factor(
```

```
    "yes",
    levels = levels(datos_modelo$internet)
  ),
  absences = 5,
  G1 = 12,
  G2 = 13
)
prediccion_nuevo <- predict(
  modelo_final,
  newdata = nuevo_estudiante,
  interval = "prediction"
)
print(prediccion_nuevo)
# 36. GUARDAR RESULTADOS
write.csv(
  comparacion,
  "comparacion_real_predicho.csv",
  row.names = FALSE
)
write.csv(
  metricas,
  "metricas_modelo.csv",
  row.names = FALSE
)
write.csv(
  tabla_coeficientes,
  "coeficientes_modelo.csv"
)
# 37. INFORMACIÓN FINAL DEL PROYECTO
cat("\n")
cat("============================================\n")
cat("    PROYECTO TDSP - STUDENT PERFORMANCE\n")
cat("============================================\n")
cat("\n")
cat("Número de estudiantes:", nrow(datos), "\n")
```

```
cat("Número de variables:", ncol(datos), "\n")

cat("\n")

cat("Métricas del modelo:\n")

cat("RMSE:", RMSE, "\n")

cat("MAE:", MAE, "\n")

cat("R^2:", R2_prueba, "\n")

cat("\n")

cat("Correlación entre valores reales y predichos:",

  correlacion_real_predicho, "\n")

cat("\n")

cat("Proceso TDSP terminado correctamente.\n")
```