UNIVERSIDAD VERACRUZANA

PREDICCIÓN DE LA SUPERVIVENCIA EN SITUACIONES DE CATÁSTROFE A PARTIR DE FACTORES SOCIOECONÓMICOS

Caso de estudio: El desastre del Titanic
Metodología: SEMMA
Modelo: Regresión logística binaria

Facultad de Estadística e Informática.
28 de septiembre de 2026

REALIZADO POR:

José Antonio Hernández Carmona, María Fernanda Arellano Pérez & Daira Lisset Landa Apolinar

ÍNDICE

1. Introducción 3
2. Planteamiento del problema 4
   2.1. Justificación
3. Objetivos 5
      3.1 Objetivos generales
      3.2 Objetivos específicos

4. Pregunta de investigación 6
5. Conjunto de datos 6
6. Metodología SEMMA.....7
   6.1. Sample — Muestra
   6.2. Explore — Explorar
   6.3. Modify — Modificar
   6.4. Model — Modelar
   6.5. Assess — Evaluar
7. Resultados e interpretación 9
8. Hipótesis.....9
   8.1. Hipótesis de investigación
   8.2. Hipótesis nula
   8.3 Resultados de hipótesis en ejemplo
9. Conclusión 10
10. 10.Bibliografía.....11

1.- INTRODUCCIÓN

La supervivencia de una persona durante una situación de catástrofe puede estar relacionada con diferentes factores, como sus características personales, familiares y condiciones socioeconómicas. El análisis de datos permite estudiar este tipo de situaciones mediante información histórica y desarrollar modelos capaces de identificar patrones y realizar predicciones.

En este trabajo se analiza la supervivencia de los pasajeros del Titanic como un caso de estudio para investigar la posible relación entre las condiciones socioeconómicas y la probabilidad de sobrevivir ante una catástrofe. El conjunto de datos contiene información de los pasajeros, incluyendo su clase, tarifa pagada, edad, sexo y características familiares, además de indicar si cada pasajero sobrevivió.

El análisis se desarrollará mediante la metodología SEMMA, la cual comprende las etapas de Sample, Explore, Modify, Model y Assess. Esta metodología permitirá realizar el análisis de manera ordenada, comenzando con la selección y exploración de los datos, continuando con su preparación y modelado, y finalizando con la evaluación de los resultados obtenidos.

Para realizar la predicción se utilizará un modelo de regresión logística binaria, debido a que la variable que se desea predecir tiene dos posibles resultados: sobrevivió o no sobrevivió. De esta manera, se buscará determinar qué variables contribuyen a explicar y predecir la supervivencia de los pasajeros.

2.- PLANTEAMIENTO DEL PROBLEMA

Las situaciones de catástrofe pueden afectar de manera diferente a las personas involucradas. En el caso del Titanic, existieron diferencias entre los pasajeros en aspectos como la clase en la que viajaban, la cantidad que pagaron por su boleto, su edad y su sexo.

A partir de estas diferencias surge el interés por analizar si las condiciones socioeconómicas de los pasajeros estuvieron relacionadas con sus posibilidades de supervivencia. En particular, se estudiarán variables como la clase del pasajero (Pclass) y la tarifa pagada (Fare), considerando también otras características que pueden influir en la supervivencia.

El problema se plantea entonces como una tarea de clasificación: utilizar la información disponible de un pasajero para estimar la probabilidad de que hubiera sobrevivido.

2.1 JUSTIFICACIÓN

El análisis de este conjunto de datos permite aplicar una metodología de minería de datos a un problema real e histórico. Además, el Titanic constituye un caso adecuado para estudiar la relación entre diferentes características de las personas y un resultado binario como la supervivencia.

La utilización de la metodología SEMMA permite organizar el proceso de análisis desde la selección de los datos hasta la evaluación del modelo predictivo. Asimismo, la regresión logística permite obtener probabilidades de supervivencia y analizar la influencia de las variables utilizadas.

Es importante señalar que el análisis busca identificar relaciones y capacidad predictiva, por lo que los resultados no deben interpretarse automáticamente como evidencia de que una determinada condición económica fue la causa de la supervivencia

3.- OBJETIVOS

3.1 OBJETIVO GENERAL

Analizar y predecir la probabilidad de supervivencia de pasajeros ante una situación de catástrofe, considerando factores socioeconómicos, personales y familiares que pueden estar relacionados con dicho resultado, mediante datos de pasajeros del Titanic como caso de estudio. Aplicando la metodología SEMMA, que permite seleccionar, explorar, modificar, modelar y evaluar el conjunto de datos, utilizando un modelo de regresión logística binaria se identifica las variables con mayor relación con la supervivencia y estima la probabilidad de que una persona sobreviva a partir de sus características.

3.2 OBJETIVOS ESPECÍFICOS

1. **Seleccionar y describir** datos que contenga información relevante sobre las características de los pasajeros y su condición de supervivencia.
2. **Explorar y analizar** la distribución de variables del conjunto de datos, identifica posibles relaciones entre las características de los pasajeros y su supervivencia.
3. **Analizar particularmente los factores socioeconómicos,** como la clase del pasajero y la tarifa pagada, para determinar su relación con la supervivencia.
4. **Identificar y tratar valores** faltantes, datos inconsistentes y variables que requieran transformación antes de realizar el modelado.
5. **Preparar el conjunto de datos** para su utilización en un modelo de clasificación, seleccionando las variables que puedan aportar información para predecir la supervivencia.
6. **Construir un modelo de regresión logística binaria** que permita estimar la probabilidad de supervivencia de un pasajero a partir de sus características.
7. **Evaluar el desempeño del modelo** predictivo mediante métricas como precisión, sensibilidad, especificidad, matriz de confusión, etc.
8. I**nterpretar los resultados** obtenidos para determinar qué variables presentan mayor relación con la probabilidad de supervivencia y analizar específicamente el comportamiento de los factores asociados al nivel económico.
9. **Aplicar de manera estructurada las etapas** de la metodología SEMMA — Sample, Explore, Modify, Model y Assess
10. **Establecer conclusiones** a partir de los resultados del modelo, considerando tanto su capacidad predictiva como las limitaciones del conjunto de datos y del análisis realizado.

4.- PREGUNTA DE INVESTIGACIÓN

¿El nivel económico de una persona influye en su probabilidad de sobrevivir ante una catástrofe?

5.- CONJUNTOS DE DATOS

Para el proyecto utilizamos el conjunto de datos Titanic, disponible en el paquete titanic de R. Contiene información de los pasajeros del Titanic y permite analizar la relación entre sus características personales, familiares y socioeconómicas con su supervivencia.

El conjunto de datos contiene variables como:

- Survived: indica si el pasajero sobrevivió (0 = no, 1 = sí).
- Pclass: clase del pasajero (1.ª, 2.ª o 3.ª).
- Sex: sexo del pasajero.
- Age: edad.
- SibSp: número de hermanos o cónyuges a bordo.
- Parch: número de padres o hijos a bordo.
- Fare: tarifa pagada por el pasajero.
- Embarked: puerto de embarque.

Para el modelo se seleccionaron principalmente Pclass y Fare como variables relacionadas con el aspecto socioeconómico, junto con variables personales y familiares como Sex, Age, SibSp, Parch y Embarked.

La variable Survived se utilizó como variable dependiente, ya que el objetivo del trabajo es predecir la probabilidad de supervivencia mediante una regresión logística binaria.

```
> names(titanic_train)
 [1] "PassengerId" "Survived"    "Pclass"      "Name"
 [5] "Sex"         "Age"         "SibSp"       "Parch"
 [9] "Ticket"      "Fare"        "Cabin"       "Embarked"
```

6- METODOLOGÍA - SEMMA

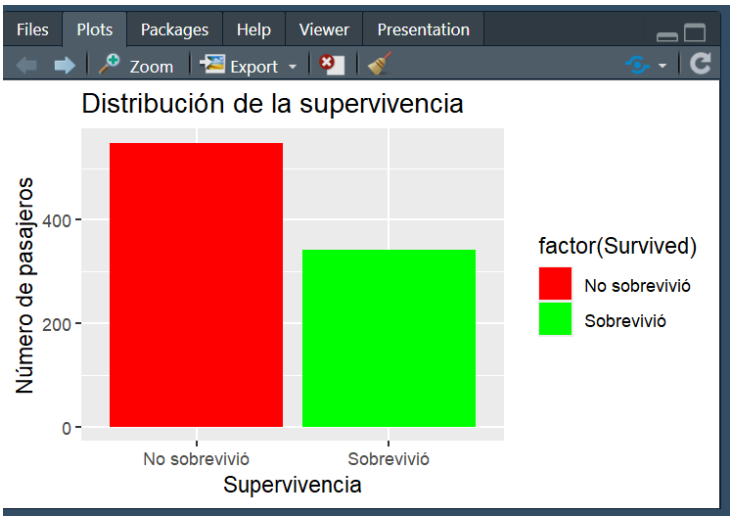
SEMMA es una metodología para desarrollar proyectos de minería de datos y análisis predictivo. Su nombre proviene de cinco etapas: Sample, Explore, Modify, Model y Assess. Cada una permite preparar los datos, analizarlos, construir un modelo y evaluar sus resultados.

6.1. Sample — Muestra

En esta etapa se selecciona el conjunto de datos que se utilizará para realizar el análisis. Utilizamos el conjunto de datos Titanic, que contiene información de los pasajeros, como su clase, edad, sexo, tarifa pagada y si sobrevivieron o no.

6.2. Explore — Explorar

Aquí se analizan los datos para conocer sus características y encontrar posibles relaciones entre las variables. En nuestro caso, exploramos principalmente la variable Survived, que indica si el pasajero sobrevivió. También observamos variables como Pclass y Fare, relacionadas con el aspecto socioeconómico.



6.3. Modify — Modificar

En esta etapa se preparan los datos para poder utilizarlos correctamente en el modelo:

- Seleccionamos las variables necesarias.
- Eliminamos registros con valores faltantes.
- Convertimos algunas variables en factores.
- Dividimos los datos en un conjunto de entrenamiento (80%) y uno de prueba (20%).

6.4. Model — Modelar

Esta es la etapa donde se construye el modelo predictivo. Utilizamos una regresión logística binaria, porque la variable Survived solamente tiene dos resultados:

- 0 = no sobrevivió
- 1 = sobrevivió

El modelo utiliza variables como Pclass, Sex, Age, Fare, entre otras, para estimar la probabilidad de que un pasajero sobreviva.

```r
#4.MODEL
#Regresión Logística binaria
modelo <- glm(
  Survived ~ Pclass + Sex + Age + SibSp + Parch + Fare + Embarked,
  data = datos_train,
  family = binomial
)
summary(modelo)
```

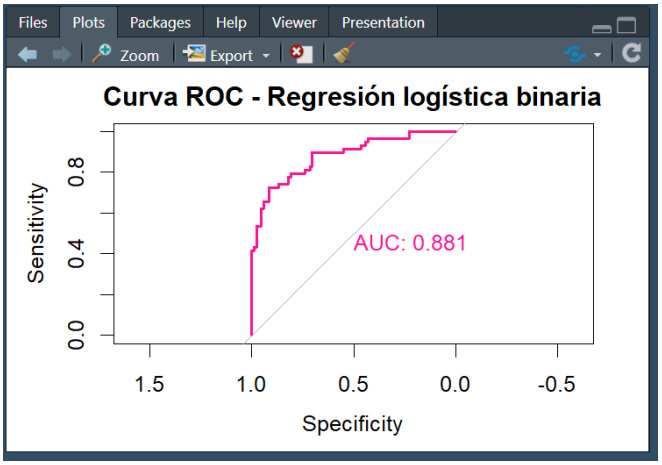
6.5. Assess — Evaluar

Finalmente, se evaluamos qué tan bien funciona el modelo con datos que no utilizamos para entrenarlo.

Utilizamos:

- Matriz de confusión
- Accuracy
- Sensibilidad
- Especificidad
- Curva ROC
- AUC

La curva ROC permite analizar la capacidad del modelo para distinguir entre pasajeros que sobrevivieron y aquellos que no.



7.- RESULTADOS E INTERPRETACIÓN

El conjunto de datos utilizado contiene 891 registros y 12 variables. Del total de pasajeros, aproximadamente 38.38% sobrevivió y el resto no sobrevivió.

En el modelo de regresión logística, las variables que mostraron una relación estadísticamente significativa con la supervivencia fueron Pclass, Sex, Age y SibSp. En particular, las categorías de segunda y tercera clase presentaron coeficientes negativos respecto a la primera clase, lo que indica una menor probabilidad estimada de supervivencia al mantener constantes las demás variables.

Por otro lado, Fare no resultó estadísticamente significativa ($p = 0.4011$), por lo que en este modelo no se encontró evidencia suficiente para relacionar directamente la tarifa pagada con la supervivencia. Esto es importante porque indica que la clase del pasajero fue un indicador más relevante que la tarifa dentro del modelo.

El modelo obtuvo una precisión de 80.99%, una sensibilidad de 74.14% y una especificidad de 85.71%. Además, presentó un AUC de 0.8805, indicando una buena capacidad para distinguir entre pasajeros que sobrevivieron y los que no.

8.- HIPÓTESIS

8.1 Hipótesis de investigación

Las variables relacionadas con las condiciones socioeconómicas de los pasajeros presentan una relación con su probabilidad de supervivencia.

8.2 Hipótesis nula

Las variables relacionadas con las condiciones socioeconómicas de los pasajeros no presentan una relación significativa con su probabilidad de supervivencia.

8.3 Resultados de hipótesis en ejemplo

Se plantea que los factores socioeconómicos, principalmente la clase del pasajero (Pclass), pueden estar relacionados con la probabilidad de supervivencia ante una situación de catástrofe. Esta relación se evaluará mediante un modelo de regresión logística binaria, considerando también otras características de los pasajeros.

De acuerdo con los resultados obtenidos, Pclass presentó una relación estadísticamente significativa con la supervivencia, mientras que Fare no presentó una relación significativa dentro del modelo. Por lo tanto, los resultados proporcionan evidencia de una relación entre la clase del pasajero y la supervivencia, aunque no permiten afirmar que el nivel económico sea la causa de la supervivencia.

9.- CONCLUSIÓN

El análisis permitió estudiar la supervivencia de los pasajeros del Titanic mediante la metodología SEMMA y un modelo de regresión logística binaria. De los 891 registros analizados, el 38.38% correspondió a pasajeros que sobrevivieron.

Los resultados mostraron que la clase del pasajero, el sexo, la edad y el número de hermanos o cónyuges a bordo fueron variables relacionadas significativamente con la supervivencia. En particular, Pclass mostró una relación importante, mientras que Fare no presentó evidencia estadísticamente significativa dentro del modelo.

El modelo obtuvo una precisión de 80.99% y un AUC de 0.8805, lo que indica una buena capacidad para distinguir entre pasajeros que sobrevivieron y quienes no. En general, el análisis permitió identificar factores asociados con la supervivencia y demostrar la utilidad de la regresión logística para realizar predicciones en este tipo de problemas.

10.- BIBLIOGRAFÍA

Cukierski, W. (2012). *Titanic - Machine Learning from Disaster*. Kaggle. https://www.kaggle.com/competitions/titanic

R Core Team. (2026). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing. https://www.r-project.org/

Canva. (s. f.). *Canva: Visual Suite for Everyone*. https://www.canva.com/

OpenAI. (2026). *ChatGPT*.